

最終レポート課題

- 各自で設定したテーマに基づいて、機械学習によるデータ分析を実装・実行し、結果をレポートにまとめてください。
 - テーマは、機械学習によるデータ分析の実装を伴うことが要件です。
 - それ以外にテーマの制約はありません。考えられるテーマの例としては以下が挙げられますが、この枠にとらわれる必要はありません。
 - 自分が興味のあるデータに対して機械学習でなんらかの予測を行うアプリケーションを作成する、開発型のテーマ
 - 複数の機械学習モデルを、複数のデータセットを用いて比較するなどして、手法の性質について考察する、分析型のテーマ
 - 機械学習手法の実装に用いるライブラリは、演習で扱うPyTorchやscikit-learnでなくても構いません。

評価の観点

- 独創性
 - プロジェクトの動機, 独自性, 重要性や意義などが説得力を持って説明されていれば加点.
- 実装の有用性
 - 一般的な公開サンプルプログラムとは異なる独自の実装が含まれていて, その有用性が説得力のある方法で示されていれば加点.
- 信頼性
 - 実行や実験の結果に対する一貫性のある議論に基づいて, 発展的な知見が説得力を持って示されていれば加点.
- 了解性
 - 体裁が整っていて分かりやすく, 実装の再現ができるだけの十分な情報が簡潔に書かれていれば加点.

レポートの形式

- レポートは PDF 形式で提出してください。レポートには、以下の3項目を必ず含めてください。
 - 目的
 - プロジェクトの動機，独自性，重要性や意義などを説明してください。
 - 方法
 - プロジェクトの手順や実装方法について説明してください。プログラムそのものを掲載する必要はありませんが，機械学習の知識を持つ読者がプロジェクトをおおよそ再現できる程度に，具体的な内容を説明してください。
 - 結果と考察
 - プロジェクトで得られた結果を示し，その結果について考察してください。期待していた結果との違いや，そのような結果になった理由などについて議論し，得られた知見を示してください。
- 分量の指定はしませんが，ごく短いレポートでは独創性や信頼性のアピールは難しいと思いますし，内容も分かりにくくなると思いますので，必然的に低い評価になる可能性が高いと解釈してください。

独自のCSVデータセットを読み込む

- 最終レポート提出ページにある「load_csv_dataset.py」を参考にしてください。

```
# Load your own CSV dataset
# Prepare a csv file as "data/my_csv_dataset.csv" in the following format
#
# sepal length (cm),sepal width (cm),petal length (cm),petal width (cm),class
# 5.1,3.5,1.4,0.2,Iris-setosa
# 4.9,3.0,1.4,0.2,Iris-setosa
# 7.0,3.2,4.7,1.4,Iris-versicolor
# 6.4,3.2,4.5,1.5,Iris-versicolor
# 6.3,3.3,6.0,2.5,Iris-virginica
# 5.8,2.7,5.1,1.9,Iris-virginica
data = pd.read_csv('data/my_csv_dataset.csv')
X = data.iloc[:, :-1].values
y_text = data.iloc[:, -1].values
y_names = sorted(set(y_text))
y_name_to_int = {name: i for i, name in enumerate(y_names)}
y = [y_name_to_int[name] for name in y_text]
```

独自の画像データセットを読み込む

- 最終レポート提出ページにある「load_image_dataset.py」を参考にしてください.

```
# Load your dataset
# Save the image data in the following folder structure.
# ./data/my_image_dataset/
#   - train/
#     - class1/
#       - 1.png
#       - ...
#     - class2/
#       - 2.png
#       - ...
#   - test/
#     - class1/
#       - 3.png
#       - ...
#     - class2/
#       - 4.png
#       - ...
from torchvision import datasets
trainval_dataset = datasets.ImageFolder(root='./data/my_image_dataset/train', transform=transform)
test_dataset = datasets.ImageFolder(root='./data/my_image_dataset/test', transform=transform)
num_classes = len(trainval_dataset.classes)
```

独自のテキストデータセットを読み込む

- 最終レポート提出ページにある「load_text_dataset.py」を参考にしてください。

```
# Load your text dataset
# This code assumes that you have train.tsv and test.tsv files in the data/my_text_dataset folder,
# which contain tab-delimited pairs of "text" and "label" for each line.
# Example of train.tsv:
#
# text    label
# Hello, world.    class1
# How are you?    class1
# I love programming.    class2
# I like machine learning.    class2
from datasets import load_dataset
from datasets import ClassLabel
dataset = load_dataset("csv", delimiter="\t",
                      data_files={"train": "./data/my_text_dataset/train.tsv",
                                   "test":  "./data/my_text_dataset/test.tsv",})
class_names = sorted(set(dataset['train']['label']))
class_label = ClassLabel(names=class_names)
dataset = dataset.cast_column("label", class_label)
num_classes = len(class_names)
print(f"Number of classes: {num_classes}")
```